Reuters 新聞檢索實驗

資訊檢索作業四 | 姓名：_____ 學號：_____
TF-IDF 與 TF-IDF 加權 Word2Vec 比較

研究問題

將 Word2Vec 的上下文資訊加入文件表示，能否比單純 TF-IDF 找到更相關的 Reuters 新聞？我分別檢查詞層級的鄰近關係，以及文件層級的搜尋排名，不把詞向量相似直接當成檢索改善。

資料與方法

Reuters-21578 採完整 ModApte 分割：TRAIN 9,603 篇、TEST 3,299 篇。小寫化、英文字母斷詞、移除固定停用詞並保留否定詞；標題加內文，UNPROC 使用 TEXT。IDF 與詞向量只用 TRAIN 建立，全部 TEST 為候選。TF = 1 + ln(count)，IDF = 1 + ln((1 + N)/(1 + DF))；查詢與文件同樣處理，L2 正規化後計算 cosine。CBOW 以上下文預測中心詞，Skip-Gram 以中心詞預測上下文；Gensim 訓練 100 維、window 5、min_count 2、15 epochs、negative 5、seed 42、workers 1。文件向量採 TF-IDF 加權平均。

評估設計

事先固定 15 個英文查詢，earn、acq、crude、grain、trade 各 3 題。文件含目標 topic 即判為相關；P@10 為前 10 名命中比例，MRR 為首篇相關文件排名倒數的查詢平均，nDCG@10 使用二元相關性及排名折扣。以下為實測的查詢等權平均。

方法	P@10	MRR	nDCG@10
TF-IDF	0.827	0.905	0.834
TF-IDF × CBOW	0.880	0.867	0.865
TF-IDF × Skip-Gram	0.880	0.917	0.881

結果與觀察

本次平均 P@10 最高為 TF-IDF × CBOW、TF-IDF × Skip-Gram（0.880）。CBOW 的 P@10 高於 TF-IDF，但 MRR 較低，顯示前十名命中與首篇相關排名不一定同步改善。結果限於本次語料、參數與查詢，不能推論普遍優劣。 CBOW 的 profit Top-5 為：loss（0.70）、profits（0.68）、swissair（0.66）、turnover（0.66）、net（0.63）。反義詞 loss 排在第一，正好說明向量相近不代表同義；swissair 的鄰近則可能反映特定公司財報語境，成因仍待回查原文。

心得與限制

我對 Semantic 的理解是：「語意相近，不代表詞彙關係相近」。更精確地說，向量反映的語意或情境接近，不保證同義、反義、上下位或可互換關係，也不保證符合相同的檢索意圖。profit 與 loss 共享財務上下文的可能性高，卻代表不同方向的結果。TF-IDF 加權平均也會失去詞序、否定與細節。因此，我不預設 Embedding 或 Skip-Gram 一定較好，而以實際排名驗證。topic 只能代理主題相關性，不能完整判斷使用者意圖；15 題、單一種子亦不足以支持普遍結論。

資料：Lewis，Reuters-21578，UCI，doi:10.24432/C52G6M。方法：Mikolov et al. (2013)，arXiv:1301.3781。
展示形式：Streamlit 五段式報告，附即時搜尋、Top-5 鄰近詞、逐題指標與報告下載。